

## I. 참가자 정보

공 모 명	제주도 신재생 에너지 활용을 통한 전력 비용 절감 및 탄소 배출 감소 분석
성 명	브다히어로 (유가을) (팀일 경우 팀명과 대표자 1인 기재)

## II. 세부 내용

### 1. 개요

#### 1-1. 아이디어 기획 핵심내용(요약)

[신재생 에너지 전력 공급 예측 모델 개발]

##### 1. 문제점

##### <공급 과잉으로 인한 대정전 위험 증가>

- 최근 전라도, 경상도, 강원도, 제주도 지역에 태양광 설비와 원자력 발전소가 증가하면서 전력 생산이 급증했다.
- 그러나 전력 수요는 이 증가를 따라가지 못해 공급 과잉이 발생했다.
- 이로 인해 대정전 위험이 증가하고 있으며, 효율적인 전력 관리가 필요하다.
- 신재생 에너지 생산량을 예측하여 전력 공급량을 조절함으로써 소비자에게는 가격적 이득을 제공하고, 공급자에게는 낭비되는 전력을 줄이며 안정적인 전력 공급을 유지할 수 있다.

##### 2. 프로젝트 목표

- 예측 모델 개발 : 태양광 발전량과 풍력 발전량을 기반으로 전력 공급량을 예측하는 모델을 개발한다.
- 효과 분석 : 예측 모델을 통해 소비자와 공급자 모두에게 전력 비용 절감 효과와 탄소 배출 감소 효과를 분석한다.

##### 3. 개발 과정

- 데이터 수집 및 상관 분석 : 기상 데이터 중 신재생 에너지 발전량과 가장 연관이 깊은 칼럼을 선정했다.
  - 태양광 발전량 : 일조, 일사와 양의 상관관계.
  - 풍력 발전량 : 풍속과 양의 상관관계, 최저운고와 음의 상관관계.

- 시계열 예측 : 선정된 기상 칼럼을 토대로 시계열 예측을 진행했다.

#### 4. 사용한 모델





- LSTM (Long Short-Term Memory) : 시계열 데이터를 처리하는 데 적합한 RNN의 변형 모델로, 장기적인 의존성을 처리할 수 있다.
- GRU (Gated Recurrent Unit) : LSTM과 유사한 기능을 하면서 더 간단한 구조를 가진 RNN 모델이다.
- Random Forest : 여러 개의 결정 트리를 사용하여 예측을 수행하는 앙상블 학습 모델로, 높은 예측 정확도를 제공한다.
- XGBoost : 그래디언트 부스팅 프레임워크의 일종으로, 성능과 속도 면에서 뛰어난 예측 모델이다.
- ARIMA (AutoRegressive Integrated Moving Average) : 시계열 데이터를 기반으로 하는 통계적 예측 모델로, 데이터의 자기 상관성을 이용한다.

#### 5. 기대 효과

- 전력 비용 절감 : 전력 수요에 맞춰 공급을 조절하여 불필요한 전력 생산을 줄이고, 이에 따라 전력 비용을 절감할 수 있다.
- 탄소 배출 감소 : 신재생 에너지의 효율적인 사용을 통해 화석 연료 사용을 줄이고, 탄소 배출을 감소시킬 수 있다.
- 안정적인 전력 공급 : 예측 모델을 통해 공급 과잉을 방지하고, 안정적인 전력 공급을 유지할 수 있다.

이 프로젝트는 전력 생산과 수요의 불균형 문제를 해결하기 위해 기상 데이터를 활용한 예측 모델을 개발함으로써, 경제적 및 환경적 이득을 동시에 추구하는 것을 목표로 한다.

#### 1-2. 활용 공공데이터

1. 제주시 전력 사용량		3. 제주 기상 통계		5. 최종 데이터셋	
 <b>전력데이터개방포털시스템</b> 가구당 평균 사용량, 전기요금 등 제주 주민들의 평균 전력 수요를 파악하고자 날짜별 데이터 수집		 <b>기상청 기상자료개방포털</b> 제주 날씨 정보 날짜별 제주 평균기온, 풍속, 습도 등 기상 정보 데이터 수집		독립 변수 모두 날짜별로 수집한 가구당 평균 전력 사용량, 기상 정보 종속 변수 날짜별 태양열 발전량, 풍력 발전량	
2. 풍력, 태양열 발전 정보		4. 연료원별 정산단가			
 <b>DATA.GO.KR</b> 공공데이터포털 풍력 발전량 날짜별 풍력 발전량 데이터 수집 태양열 발전량 날짜별 태양열 발전량 데이터 수집		 <b>EPSIS</b> 전력통계정보시스템 연료원별 정산단가 원자력, 유류, 신재생 에너지 등 연료원별 정산단가 데이터 수집 ↓ 추후 수요 공급 최적화 예측값에 따라 절약한 값을 계산하기 위함.			
구분	제공기관	데이터명	내용	링크	
1	전력데이터 개방 포털시스템	제주시 가구 평균 전력 사용량	지역구분, 대상가 구수(호), 가구당 평균 사용량 (kWh), 가구당 평 균 전기요금(원)	<a href="https://bigdata.kepco.co.kr/cms/main.do?scode=S01&amp;pcode=000171&amp;pstate=L&amp;redirect=Y">https://bigdata.kepco.co.kr/cms/main.do?scode=S01&amp;pcode=000171&amp;pstate=L&amp;redirect=Y</a>	
2	공공데이터포털	제주에너지공사_풍력발전기 전력 정보	일시, 가시리풍력, 김녕풍력, 동북풍력, 풍력전체 등	<a href="https://www.data.go.kr/data/15028181/fileData.do#/layer_data_information">https://www.data.go.kr/data/15028181/fileData.do#/layer_data_information</a>	
3	공공데이터포털	제주에너지공사_태양광발전기 전력 정보	일시, 교래태양광, 종합경기장 태양광, 태양광전체 등	<a href="https://www.data.go.kr/data/15038930/fileData.do">https://www.data.go.kr/data/15038930/fileData.do</a>	
4	기상자료개방포털	조건별 기후통계	일시, 평균기온, 강수량, 풍속, 습도 등	<a href="https://data.kma.go.kr/climate/RankState/selectRankStatisticsDivisionList.do">https://data.kma.go.kr/climate/RankState/selectRankStatisticsDivisionList.do</a>	
5	전력통계정보시스템	연료원별 정산단가	원자력, 유류, 신재생 에너지 등 별 정산단가	<a href="https://epsis.kpx.or.kr/epsisnew/selectEkmaUpsBftChart.do?menuId=040701">https://epsis.kpx.or.kr/epsisnew/selectEkmaUpsBftChart.do?menuId=040701</a>	

### 1-3. 제안 배경 및 필요성

#### (1) 신재생 에너지와 탄소 중립의 중요성

기후 변화와 환경 오염 문제로 인해 전 세계적으로 신재생 에너지에 대한 관심과 투자가 증가하고 있다. 특히 제주도는 대한민국에서 신재생 에너지의 선도적인 역할을 수행하고 있으며, 2030년까지 Carbon Free Island를 목표로 정책을 추진 중이다. 제주도는 환경 보호와 지속 가능한 발전을 위해 탄소 배출 감소가 시급한 과제인 것이다. 신재생 에너지를 통해 화석 연료 의존도를 줄이고 탄소 배출을 줄이는 것은 전력 수요 공급 불일치 문제 해결에 긍정적 영향을 끼칠 것이며 공급과잉 혹은 공급부족으로 인해 낭비되는 비용 또한 해결될 것이다.

#### (2) 제주도의 에너지 특성

제주도는 풍력과 태양광 같은 풍부한 자연 자원을 보유하고 있어 신재생 에너지 활용에 최적화된 지역이다. 섬 지역 특성상 에너지 자립도가 중요하며, 본토와의 전력 연결이 제한적 이므로 독자적인 에너지 관리가 필요하다. 따라서 신재생 에너지의 활용은 에너지 자립도를 높여 외부 의존도를 줄일 것이다.

#### (3) 정부 및 지역 사회의 지원

아래 ‘제주도 에너지’를 키워드로 검색한 네이버 뉴스기사 감성분석 결과 전반적인 제주도 에너지 문제에 대해 긍정적인 여론과 인식이 보여진다. 정부는 신재생 에너지 프로젝트에 대한 정책적, 재정적 지원을 제공하고 있고, 지역 사회의 인식 변화와 참여가 활성화되고 있어, 본 연구가 설정한 주제 또한 이러한 참여에 실질적인 기여가 될 것이다.

Beautifulsoap을 이용해 크롤링한 ‘제주도 에너지’ 뉴스기사 제목 데이터를 바탕으로 네이버 CLOVA Sentiment API를 호출해 감성분석한 시각화 결과는 아래와 같다.

제주도 에너지 뉴스기사 감성분석



## 1-4. 아이디어의 독창성

### (1) 탄소 배출 감소 분석

예측된 태양광 및 풍력 발전량 데이터를 바탕으로, 기존의 화석 연료 기반 발전에 비해 절감된 탄소 배출량을 계산했다. 이를 통해 신재생 에너지 활용이 환경에 미치는 긍정적인 영향을 정량적으로 평가했다.

#### 탄소 배출 감소 비율 계산

- 화석 연료 기반 발전의 기존 탄소 배출량을 합산
- 예측된 신재생 에너지 발전량을 이용하여 감소된 탄소 배출량을 계산
- 탄소 배출 감소 비율 = ((신재생 에너지 활용 후 탄소 배출량- 기존 탄소 배출량) / 기존 탄소 배출량) \* 16.8

### (2) 전력 비용 절감 분석

본 연구는 연료원별 정산단가 데이터를 이용하여, 신재생 에너지 활용으로 인해 절약된 정산단가 비용을 산정했다. 이를 통해 신재생 에너지 도입의 경제적 효과를 구체적으로 평가했다.

#### 절약된 정산단가 비용 계산

- 각 연료원의 단위 발전 비용 데이터를 바탕으로 기존 화석 연료 발전 비용 산정
- 예측된 신재생 에너지 발전량을 이용하여 절약된 비용 계산
- 절약된 정산단가 비용 = 기존 화석 연료 발전 총 비용 - 신재생 에너지 활용 후 총 비용

### (3) 독창성 및 기여

본 연구의 독창성은 단순히 태양광 및 풍력발전량 예측에 그치지 않고, 이를 바탕으로 실제 절감된 탄소 배출 비율과 연료원별 절약된 정산단가 비용을 정량적으로 계산했다는 점에 있다. 이러한 접근을 통해 신재생 에너지 활용의 경제적 및 환경적 효과를 종합적으로 평가하고, 정책 결정자 및 관련 이해관계자들에게 유용한 정보를 제공할 수 있다.


## 1-5. 아이디어의 구체성

### 1. 상관분석

본 연구는 2022~2023년의 날짜별 총 730개 행 전처리 데이터를 바탕으로 발전량(=공급량)을 예측하는 모델링을 진행하기 위해 독립변수 - 종속변수 간 상관관계 분석을 우선적으로 진행하여, 중요 피처만 선정하는 과정을 거쳤다.

#### (1) 기상데이터-태양광발전량 간의 상관관계

Scipy 라이브러리의 피어슨 상관분석 메서드를 호출하여 상관분석을 진행한 결과는 아래와 같다.

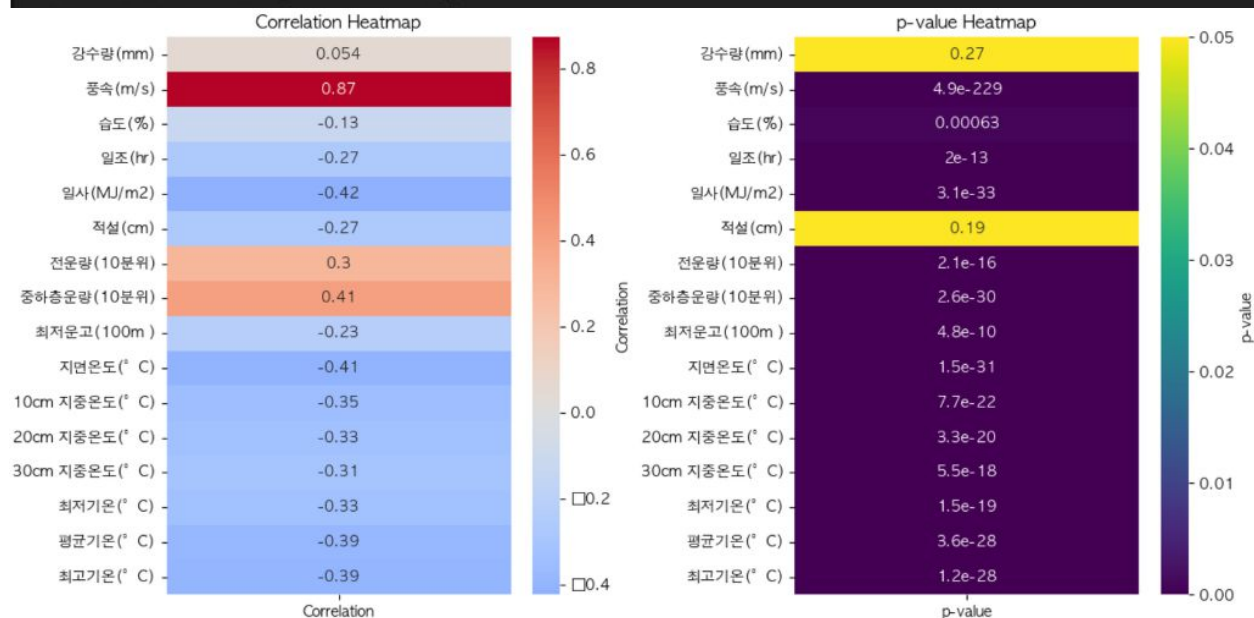


위와 같은 결과에서 상관계수 절대값이 0.5 이상이면서 p-value가 유의미한 독립변수만 채택하였다. 그 결과 일조, 일사, 전운량, 중하층운량이 태양광 발전량과 깊은 상관관계가 있음을 확인하고 모델링에 포함될 독립변수로 선정하였다.

#### (2) 기상데이터-풍력발전량 간의 상관관계

Scipy 라이브러리의 피어슨 상관분석 메서드를 호출하여 상관분석을 진행한 결과는 아래와 같다.

	Correlation	P-Value
일조(hr)	0.718802	4.745674e-117
일사(MJ/m2)	0.782852	3.648018e-152
전운량(10분위)	-0.657160	1.880504e-91
중하층운량(10분위)	-0.697442	1.933139e-107




위와 같은 결과에서 상관계수 절대값이 0.4 이상이면 p-value가 유의미한 독립변수만 채택하였다. 그 결과 풍속, 일사, 중하층운량, 지면온도가 풍력 발전량과 깊은 상관관계가 있음을 확인하고 모델링에 포함될 독립변수로 선정하였다.

### (3) 기상데이터-태양광+풍력발전량 병합 데이터 간의 상관관계

Scipy 라이브러리의 피어슨 상관분석 메서드를 호출하여 상관분석을 진행한 결과는 아래와 같다.



	Correlation	P-Value
풍속(m/s)	0.872853	4.884210e-229
일사(MJ/m2)	-0.424088	3.144709e-33
중하층운량(10분위)	0.405831	2.571808e-30
지면온도(°C)	-0.413720	1.491741e-31



위와 같은 결과에서 상관계수 절대값이 0.5 이상이면서 p-value가 유의미한 독립변수만 채택하였다. 그 결과 태양광에서 유의미하고 강한 상관관계 나타내는 기상 컬럼은 일조, 일사, 풍력에서 유의미하고 강한 상관관계 나타내는 기상 컬럼은 풍속, 최저운고임을 확인하고 모델링에 포함될 독립변수로 선정하였다.

추가로 히트맵 시각화 결과 일부분에서 독립변수 간 강한 상관관계로 다중공선성 문제가 발생하지만, 본 연구가 모델로 사용할 시계열분석과 딥러닝 모델에는 영향을 미치지 않기 때문에 별도로 고려하지 않았다.



## 2. 모델링

모델링 단계는 시계열 예측 모델 적용을 위한 데이터 전처리 과정, 모델 정의 및 학습, 그리고 성능 평가로 구성된다.


### (1) 데이터 수집 및 전처리

본 연구에서는 2022~2023년의 날짜별 데이터와 동일 기간의 기상 데이터를 결합한 데이터셋을 사용한다. 이전 상관분석 결과를 바탕으로, 태양광 발전량과 풍력 발전량에 각각 유의미한 관계를 가진 독립변수만을 선택했다. 데이터셋의 '일시' 컬럼은 날짜 형식으로 변환하고, 기상 데이터에서 발견된 결측치는 예측 수행 시 변수의 다양성을 유지하기 위해 0으로 대체했다.

성능 향상을 위해 Min-Max 스케일링을 적용하고, LSTM/GRU 모델의 입력 형식에 맞게 시계열 데이터를 변환한다. 마지막으로 데이터를 학습 및 테스트 데이터셋으로 분할하고, 과적합 방지를 위한 조기 종료 콜백을 설정한다.

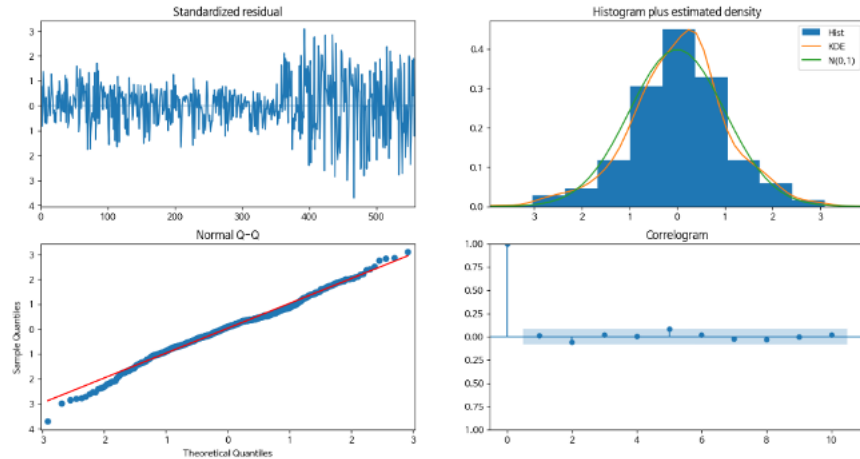
### (2) 모델 정의 및 학습

여러 모델을 사용하여 예측을 수행했다. LSTM과 GRU 모델은 각각 50개 유닛을 가진 레이어를 사용하여 시계열 데이터의 장단기 의존성을 학습한다. 두 모델 모두 ReLU 활성화 함수로 비선형성을 추가하고, Adam 옵티마이저와 MSE 손실 함수를 사용한다. 학습은 최대 100 에포크, 배치 크기 32로 설정하며, 검증 손실이 10 에포크 동안 개선되지 않으면 아래 사진과 같이 학습을 중단하고 최적 가중치를 복원한다.




Random Forest와 XGBoost 모델은 각각 100개의 결정 트리와 100개의 부스팅 스테이지를 사용한다. 두 모델 모두 재현성을 위해 랜덤 시드를 42로 설정하고, 1차원으로 평탄화된 타겟 데이터를 사용하여 학습한다.

ARIMA 모델의 경우, 원본 데이터에서 결측치만 제거하고 스케일링을 적용하지 않는다. KPSS 및 ADF 테스트로 최적 차분 횟수를 결정하고, Auto\_arima 함수로 모델을 자동 설정한다. 모델 진단은 아래 그림과 같이 표준화된 잔차에서는 잔차가 일정한 범위 내에 있고 패턴이 없음을 확인했고, 히스토그램은 잔차의 분포가 정규 분포를 따르고 있음을 알 수 있다. Q-Q 플롯에서는 잔차가 이론적 정규 분포선에 근접했으며, 상관도를 통해 잔차의 자기상관이 거의 없다는 것을 알 수 있어 예측을 수행하는데 forecast\_one\_step 함수를 정의해 테스트 데이터 `test\_data`에 대해 ARIMA 모델을 사용한다.



이 때, 한 단계 예측과 신뢰 구간을 계산하고 모델은 각 예측 단계마다 업데이트되어 새로운 관측값을 반영한다.

### (3) 성능 평가



위 그림에서는 실제값에 따라 5가지 모델이 얼마 만큼 예측을 하는 지 한 눈에 확인하기 위해 시각화를 했다. 하지만 실제값에 따라 예측이 어느 정도로 수행되는지는 확인하기 어려워 모델의 성능을 MSE, MAE, NMAE, R2, Accuracy의 값들을 테이블 형태로 확인해 어느 모델의 성능이 가장 좋은지를 확인할 수 있다.

	MSE	MAE	NMAE	R2	Accuracy
LSTM	9.515340e+06	2608.674952	108.676677	0.012879	1.287902
GRU	2.358802e+07	4098.961306	170.761594	-1.447020	0.000000
Random Forest	3.909756e+06	1526.090972	63.576528	0.594402	59.440207
XGBoost	5.356240e+06	1827.474254	76.132072	0.444344	44.434384
ARIMA	6.928493e+06	2136.43181	89.003158	0.281238	28.123837

위 표와 같이 모든 성능 지표에서 타 모델 대비 Random Forest 모델이 좋은 성능을 보이고 있음을 확인 할 수 있다.

성능 지표에서 사용된 NMAE는 김상진, 유재혁, 장병훈, & 우성민. (2022). 머신러닝 기반의 예측 시장 참여를 위한 태양광 발전량 예측 알고리즘 및 수익성에 관한 연구. *한국태양에너지학회 논문집*, 42(6), 173-183. 연구에 따르면 Normalized Mean Absolute Error를 의미하며 오차를 설비용량 대비 비율로 나타내어 백분율로 아래의 식으로 표현한다.

$$NMAE(\%) = \frac{100}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{S} \right|, \quad A_t \geq 0.1 \times S$$

이는 다른 규모의 시스템 간 성능 비교를 가능하게 하며, 실제 운용 상황에서의 모델 성능을 평가하는데 유용하다. 또한, 정규화된 값을 사용하므로 시간에 따른 발전량 변화나 계절적 변동에 관계없이 일관된 기준으로 예측 성능을 평가할 수 있어, 미래의 다양한 발전 상황에 대한 모델의 예측 성능 비교에 유리하다. 하지만 모델의 전반적인 성능을 종합적으로 평가하기 위해 MSE, MAE 등 다른 지표들과 함께 고려했다.


### (3) 모델 성능 개선

풍력 발전량에 대해서는 성능이 잘 나온다고 판단 하여 태양광 발전량은 비교적 성능이 대체로 낮게 나와 성능 개선을 진행했다. 성능 개선을 위해 사용된 방법으로는 그리드 서치와 교차 검증, ARIMA 모델에서는 Min-Max 스케일링을 적용했다.

우선, LSTM과 GRU모델에 대해 최적의 유닛 개수와 옵티마이저를 탐색하고, 검증 데이터 셋을 사용하여 각 하이퍼파라미터 조합의 성능을 평가해 최적의 모델을 선정한다. 선정된 최적의 모델로 테스트 데이터 셋에 대해 예측을 수행하고 성능을 평가한다.

다음 Random Forest와 XGBoost의 모델의 경우 결정 트리 개수, 최대 깊이, 학습률 등의 하이퍼파라미터를 탐색하고 시계열 교차 검증을 통해 각 조합의 성능을 평가하고 최적의 모델을 선정한다. 마찬가지로 선정된 최적의 모델로 테스트 데이터 셋에 대해 예측을 수행하고 성능을 평가한다.

마지막으로 성능 개선 전 ARIMA 모델은 원본 데이터를 그대로 사용했지만, Min-Max 스케일링을 적



용한 후 스케일 된 데이터를 사용해 동일하게 모델링을 수행해 학습한다.

위 그림과 같이 실제값과 예측값을 시각화 했을 때의 그래프이고 다음 표에서 5가지 모델 중 성능이 어떻게 개선되었는지 확인할 수 있다.

	MSE	MAE	NMAE	R2	Accuracy
LSTM	7.236497e+06	2220.925302	92.523134	0.190026	19.002631
GRU	6.808531e+06	2160.566194	90.008590	0.237928	23.792813
Random Forest	4.123370e+06	1607.174712	66.954454	0.538475	53.847545
XGBoost	4.622550e+06	1710.878550	71.274727	0.482603	48.260271
ARIMA	7.157377e+06	2175.958924	90.649847	0.260654	26.065439

모델 개선 전과 후를 비교했을 때, 성능이 비교적 올랐지만 그럼에도 Random Forest 모델이 가장 성능이 좋은 것을 확인할 수 있다.

#### (4) 풍력 발전량 성능 평가와 시각화


풍력 발전량도 태양광 발전량 예측 프로세스를 그대로 적용해 성능 평가를 진행하고, 실제값과 예측값을 시각화 해 모델의 성능과 예측이 어떻게 이루어지는지 확인한다.

	MSE	MAE	NMAE	R2	Accuracy
LSTM	47473993574.148	159813.272770	292.275843091	0.1761323	17.613227
GRU	62653826224.760	210860.505959	377.485126609	-0.0872998	0.000000
Random Forest	7003426231.761	59557.721282	110.323505000	0.8680126	86.801263
XGBoost	9866394220.134	71706.938069	132.831872085	0.8140568	81.405681
ARIMA	70326094859.472	176844.297208	323.940395619	-0.3253736	0.000000

#### (5) 결론

본 연구에서는 태양광 및 풍력 발전량 예측을 위해 다양한 머신러닝 및 시계열 분석 모델을 적용하고 성능을 비교 분석하였으며, 그 결과 태양광 발전량 예측에서는 초기 모델링과 모델 개선 후 모두 Random Forest 모델이 가장 우수한 성능을 보였고 모든 모델에서 전반적인 성능 향상이 관찰되었는

실제값과 예측된 풍력 발전량 그래프



데, 특히 LSTM과 GRU 모델의 개선이 두드러졌다. 풍력 발전량 예측에서도 Random Forest 모델이 가장 높은 성능을 보였으며, XGBoost 모델 역시 우수한 성능을 나타냈고 LSTM 모델은 중간 정도의 성능을 보인 반면 GRU와 ARIMA 모델은 상대적으로 낮은 성능을 보였다. 전체적으로 태양광과 풍력 발전량 예측 모두에서 Random Forest 모델이 일관되게 우수한 성능을 보였으며, 딥러닝 모델인 LSTM과 GRU는 태양광 발전량 예측에서 개선 후 성능이 향상되었으나 풍력 발전량 예측에서는 상대적으로 낮은 성능을 보였고, ARIMA 모델은 두 경우 모두에서 상대적으로 낮은 성능을 나타냈다. 이러한 결과를 바탕으로 태양광 및 풍력 발전량 예측에 있어 Random Forest 모델이 가장 신뢰할 만한 결과를 제공할 것으로 예상되나, 시계열 데이터의 특성을 고려할 때 LSTM이나 GRU와 같은 딥러닝 모델의 지속적인 개선 및 최적화가 필요할 것으로 보이며, 실제 적용 시에는 모델의 성능뿐만 아니라 해석 가능성, 계산 복잡도, 업데이트 용이성 등을 종합적으로 고려해야 할 것이다. 본 연구 결과는 재생에너지 발전량 예측의 정확도를 높이는 데 기여할 수 있으며, 이는 전력 계통 운영의 안정성과 효율성 향상에 도움이 될 것으로 기대된다.

## 2-1. 기대효과 및 결론

‘1-4. 아이디어 독창성’에서 설명한 바와 같이 본 연구는 단순히 태양광 및 풍력발전량 예측에 그치지 않고, 이를 바탕으로 실제 절감된 탄소 배출 비율과 연료원별 절감된 정산단가 비용을 정량적으로 계산했다는 점에 있다. 앞선 시계열 분석 후 예측된 발전량과 실제 발전량을 비교해 절감된 탄소 배출량과 최종적으로 절감된 연료원별 정산단가 비용을 집계한 신재생 에너지의 경제적 효과는 아래와 같다.

### (1) 태양광 탄소 배출량

전체 실제 발전량: 4007946.38  
 전체 예측된 발전량: 3723911.20  
 발전량 차이: -284035.18  
 탄소 배출량 감소 비율: -1.19%

### (2) 풍력 탄소 배출량

전체 실제 발전량: 175505276.27  
 전체 예측된 발전량: 175962288.02  
 발전량 차이: 457011.75  
 탄소 배출량 감소 비율: 0.04%

### (3) 태양광 정산 단가 가격 이득

[730 rows × 6 columns]

전체 실제 태양광 발전량 총 가격 : 686372438.56

전체 예측된 태양광 발전량 총 가격 : 649136044.85

총 태양광 가격 차이 : -37236393.71

	월	실제값_풍력_총가격	예측값_풍력_총가격	풍력_가격_차이
0	2022-01	2003420227.33	1931182045.13	-72238182.20
1	2022-02	2424176062.94	2395544858.99	-28631203.95
2	2022-03	1751031755.99	1693725049.56	-57306706.43
3	2022-04	972873144.69	1007753049.00	34879904.31
4	2022-05	685142168.29	672758908.95	-12383259.33
5	2022-06	879193166.77	858427579.26	-20765587.51
6	2022-07	925342840.85	881116113.07	-44226727.78
7	2022-08	723979617.09	865524998.67	141545381.58
8	2022-09	1645460151.30	1687387273.00	41927121.70
9	2022-10	2079092327.63	2142788818.13	63696490.51
10	2022-11	1706940549.06	1657054835.37	-49885713.69
11	2022-12	2022759499.08	2118556117.28	95796618.20
12	2023-01	1804070325.68	1803672115.09	-398210.59
13	2023-02	1222393009.88	1201678223.57	-20714786.31
14	2023-03	1076940916.08	1145885637.15	68944721.08
15	2023-04	1345660389.12	1398018314.13	52357925.01
16	2023-05	904289707.02	869186553.38	-35103153.64
17	2023-06	574086942.08	615937542.28	41850600.20
18	2023-07	826115509.12	852228539.00	26113029.88
19	2023-08	665838988.15	662618462.43	-3220525.72
20	2023-09	520095820.63	530389486.65	10293666.02
21	2023-10	885241871.90	814025003.08	-71216868.82
22	2023-11	1261569562.59	1218605600.73	-42963961.86
23	2023-12	1281436691.04	1316316259.42	34879568.39

	월	실제값_태양_총가격	예측값_태양_총가격	태양_가격_차이
0	2022-01	13690745.37	16831146.00	3140400.63
1	2022-02	20932394.73	22462366.54	1529971.81
2	2022-03	28824602.81	30589986.59	1765383.78
3	2022-04	33214313.87	37359778.89	4145465.02
4	2022-05	22824420.21	24705997.83	1881577.62



#### (4) 풍력 정산단가 가격 이득

전체 실제 풍력 발전량 총 가격 : 30187151244.30

전체 예측된 풍력 발전량 총 가격 : 30340381383.32

총 풍력 가격 차이 : -37236393.71

위의 결과를 종합하면 태양광의 경우 실제 수요를 고려한 발전량(=공급량)이 감소한 반면, 풍력의 경우 예측 발전량이 증가한 것을 확인할 수 있다. 단순히 발전량이 증가해, 정산단가 비용까지 높아진 것이 아닌, 제주도의 전력 수요와 일치한 최적의 발전량을 구한 것이기에 이상적인 값이 나왔다고 할 수 있다.

제주시가 본 연구의 모델을 적용하면, 신재생 에너지 활용을 통한 경제적 효과를 크게 누릴 수 있을 것이다. 연구의 분석 결과는 신재생 에너지의 적극적인 활용이 탄소 배출 감소와 전력 비용 절감이라는 두 가지 중요한 목표를 동시에 달성할 수 있음을 명확히 보여준다.

특히, 태양광과 풍력 발전량을 정확히 예측함으로써 제주시가 효율적인 에너지 관리와 비용 절감을 실현할 수 있다. 예측된 발전량을 기반으로 절감된 탄소 배출 비율과 연료원별 절약된 정산단가 비용을 구체적으로 산출한 것은, 신재생 에너지 도입의 경제적 효과를 정량적으로 평가하는 데 큰 기여를 할 것이다.

